

Tarea 3.4 – Análisis de Variantes con CLC Genomics Workbench

Autora: Martha Flórez

Fecha: 15.11.2025

Curso: Bioinformática Reproductiva 2025

1. Introducción

En este análisis se ejecutó un flujo de trabajo completo para la identificación, evaluación y anotación de variantes a partir de datos de **secuenciación de exoma (WES)** utilizando **CLC Genomics Workbench 25**.

El objetivo principal fue:

- Evaluar la calidad del enriquecimiento de regiones objetivo
- Detectar variantes somáticas
- Interpretar clínicamente variantes relevantes
- Elaborar un informe siguiendo guías **AMP/ASCO/CAP**

Los datos corresponden a un caso real de carcinoma de células acinares publicado por Nichols et al. (2013).

El dataset contempla una fracción del **cromosoma 5**.

2. Control de calidad del enriquecimiento

2.1 Cobertura promedio de las regiones objetivo

La distribución de la cobertura mostró:

- **Cobertura promedio:** 22.5x
- **Mediana:** 18x
- **Cobertura mínima:** 0x
- **Regiones con $\geq 10x$:** 82.6%

1 Target regions

1.1 Summary

Number target regions	124
Total length of targeted regions	22.946
Minimum coverage	0
Maximum coverage	106
Average coverage	22,5
Median coverage	18,0
Number of target regions with coverage < 10	72
Total length of target regions containing positions with coverage < 10	13.020
Total length of target region positions with coverage < 10	3.992
Total length of target region positions with coverage ≥ 10	18.954
Percentage of target region positions with coverage ≥ 10 (%)	82,6

1.2 Fractions of targets with coverage at least 10

Number of targeted regions for which	Count	Percentage
≥100% of the targeted region has coverage at least 10	52	41,94
≥90% of the targeted region has coverage at least 10	75	60,48
≥80% of the targeted region has coverage at least 10	88	70,97
≥70% of the targeted region has coverage at least 10	96	77,42
≥60% of the targeted region has coverage at least 10	100	80,65
≥50% of the targeted region has coverage at least 10	104	83,87
≥40% of the targeted region has coverage at least 10	107	86,29
≥30% of the targeted region has coverage at least 10	107	86,29
≥20% of the targeted region has coverage at least 10	107	86,29
≥10% of the targeted region has coverage at least 10	107	86,29
≥0% of the targeted region has coverage at least 10	124	100,00

Figura 1. Distribución de cobertura promedio en regiones objetivo *La figura evidencia variabilidad marcada en la profundidad de lectura entre regiones, incluyendo segmentos con <10x.*

Interpretación:

Aunque la cobertura promedio es aceptable para análisis germinal, es insuficiente para estudios somáticos, donde se recomiendan ≥50x. Esto genera riesgo de no detectar variantes heterocigotas o de baja frecuencia.

2.2 Especificidad del mapeo en targets

Resultados:

- **36.5%** de lecturas dentro de regiones target
- **29.1%** de bases en regiones target

2 Targeted region overview

Reference	Total mapped reads	Mapped reads in targeted region	Specificity (%)	Total mapped reads excl ignored	Mapped reads in targeted region excl ignored	Specificity excl ignored (%)
5	21.952	8.008	36,48	21.952	8.008	36,48

Reference	Total mapped bases	Mapped bases in targeted region	Specificity (%)	Total mapped bases excl ignored	Mapped bases in targeted region excl ignored	Specificity excl ignored (%)
5	1.769.422	515.539	29,14	1.769.422	515.539	29,14

Figura 2. Porcentaje de lecturas y bases mapeadas al panel

Interpretación:

En WES esperábamos $\geq 50\%$ de lecturas en targets.

En paneles dirigidos $\geq 90\%$.

El valor obtenido indica **enriquecimiento pobre**, lo cual:

- Aumenta ruido fuera del target
- Reduce cobertura efectiva
- Disminuye sensibilidad de variantes

2.3 Cobertura de objetivos específicos

Resultados:

- **124 regiones objetivo**
- **72 regiones** con cobertura $< 10\times$
- **52 regiones (42%)** con cobertura completa $\geq 10\times$

1.2 Fractions of targets with coverage at least 10

Number of targeted regions for which	Count	Percentage
$\geq 100\%$ of the targeted region has coverage at least 10	52	41,94
$\geq 90\%$ of the targeted region has coverage at least 10	75	60,48
$\geq 80\%$ of the targeted region has coverage at least 10	88	70,97
$\geq 70\%$ of the targeted region has coverage at least 10	96	77,42
$\geq 60\%$ of the targeted region has coverage at least 10	100	80,65
$\geq 50\%$ of the targeted region has coverage at least 10	104	83,87
$\geq 40\%$ of the targeted region has coverage at least 10	107	86,29
$\geq 30\%$ of the targeted region has coverage at least 10	107	86,29
$\geq 20\%$ of the targeted region has coverage at least 10	107	86,29
$\geq 10\%$ of the targeted region has coverage at least 10	107	86,29
$\geq 0\%$ of the targeted region has coverage at least 10	124	100,00

Figura 3. Targets cubiertos a $\geq 10\times$

Interpretación:

Solo 42% de regiones presentan cobertura ideal.

Para un análisis clínico real se exige $\geq 90\%$ de regiones con cobertura sólida. Aquí observamos cobertura fragmentada e insuficiente.

3. Identificación de variantes

Tras mapeo, realineamiento local y llamada de variantes, se visualizó el genoma a nivel de target.




Figura 4. Vista del Genome Browser mostrando genes, CDS, mRNA y regiones target

La tabla de variantes muestra:

- Variantes con frecuencias desde 25% a $>90\%$
- Algunas con pocas lecturas únicas (riesgo de error PCR)
- Variantes con baja calidad base

Identified_variants-tumor_re... x

Target_region_coverage-tumor... x

Rows: 13 / 16

Table view: Homo sapiens

Filter to Selection...

☒ Match any

☐ Match all

⌵

Filter Sets...

Reference allele

contains

no

+

×

Filter

Chromosome	Region	Type	Reference	Allele	Reference al...	Length	Zygosity	Count	Coverage	Frequency
5	68396764^68396765	Insertion	-	G	No		1 Homozygous	11	12	91,67
5	68412048^68412049	Insertion	-	T	No		1 Homozygous	7	7	100,00
5	68413043	Deletion	T	-	No		1 Homozygous	38	39	97,44
5	68417755	SNV	A	G	No		1 Homozygous	7	7	100,00
5	68419054	SNV	A	T	No		1 Homozygous	11	11	100,00
5	68464234	SNV	A	G	No		1 Heterozygous	10	17	58,82
5	68471247	SNV	G	A	No		1 Heterozygous	12	25	48,00
5	68524006^68524007	Insertion	-	T	No		1 Homozygous	11	11	100,00
5	68531253	SNV	C	T	No		1 Homozygous	13	13	100,00
5	68602746	SNV	G	C	No		1 Homozygous	9	9	100,00
5	68609885	SNV	G	T	No		1 Homozygous	13	13	100,00
5	68695940	SNV	T	G	No		1 Heterozygous	3	12	25,00
5	68715310	SNV	C	T	No		1 Homozygous	22	22	100,00

Figura 5. Lista de variantes detectadas

**4. Interpretación clínica (AMP/ASCO/CAP)

Se seleccionaron variantes para análisis clínico mediante:

- ClinVar
- VarSome
- CIViC
- OncoKB

Hallazgos principales

- Ninguna variante pertenece a genes accionables de alto impacto (BRCA1/2, TP53, EGFR, KRAS).
- No se identificaron mutaciones catalogadas como *tier I* (alto nivel de evidencia) ni *tier II* (significancia potencial).
- La mayoría de variantes muestran soporte limitado o baja profundidad → posible **artefacto técnico**.
- Varias variantes se ubican en regiones con cobertura insuficiente, limitando interpretación.

5. Conclusiones del análisis

1. **La cobertura global del experimento fue insuficiente**, especialmente en regiones críticas del panel.
2. **La especificidad del mapeo es baja (36.5%)**, lo que afecta la eficiencia de captura.
3. **Sólo 42% de los targets presenta cobertura adecuada ($\geq 10\times$)**.

4. Las variantes identificadas presentan **baja calidad**, y ninguna posee relevancia clínica según AMP/ASCO/CAP.
5. Para análisis clínicos se recomienda:
 - Optimizar captura de exoma
 - Reevaluar preparación de librería
 - Aumentar profundidad mínima a $\geq 80\times$
6. El workflow permite reproducir una ruta estándar de análisis de variantes en CLC, confirmando su utilidad en entornos educativos y de entrenamiento.